



# Ciencia de Datos y BigData

## Análisis y Curación - Sesgo

**Dr. José Ramón Iglesias**



DSP-ASIC BUILDER GROUP  
Director Semillero TRIAC  
Ingeniería Electronica  
Universidad Popular del Cesar

# **Statistical, Machine Learning and Social Bias**



**Low Variance**  
(Precise)

**High Variance**  
(Not Precise)


**Low Bias**  
(Accurate)



**High Bias**  
(Not Accurate)



# Tipos de sesgo.... entre los millones que hay



THIS IS YOUR MACHINE LEARNING SYSTEM?

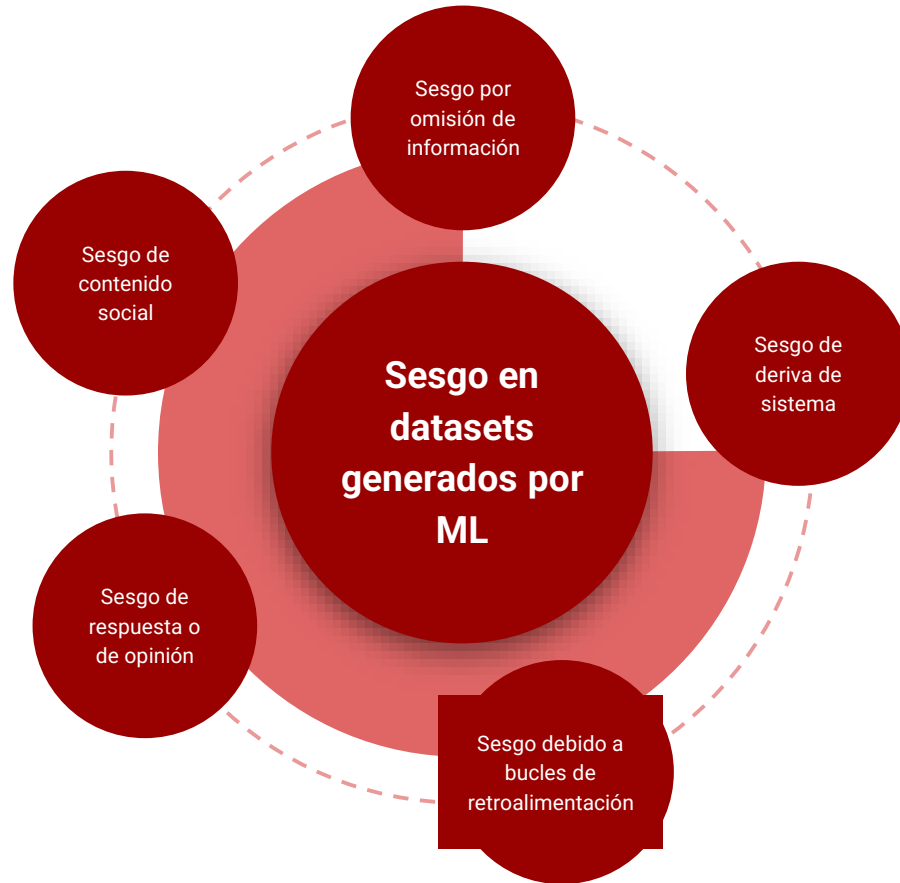
YUP! YOU POUR THE DATA INTO THIS BIG  
PILE OF LINEAR ALGEBRA, THEN COLLECT  
THE ANSWERS ON THE OTHER SIDE.

WHAT IF THE ANSWERS ARE WRONG?

JUST STIR THE PILE UNTIL  
THEY START LOOKING RIGHT.



# Sesgo en Datasets creados automáticamente



# Tipo de sesgo en generación automática

- ❖ **Sesgo por omisión de información:** este tipo de sesgo ocurre cuando faltan variables relevantes para la caracterización del problema.
- ❖ **Sesgo de deriva de sistema:** la deriva ocurre cuando el sistema de generación de datos cambia con el tiempo.
- ❖ **Sesgo de contenido social:** ocurre cuando se incluye información con sesgos sociales, como estereotipos de género y raza.
- ❖ **Sesgo de respuesta o de opinión:** ocurre cuando el contenido es generado por personas, reviews on Amazon, Twitter tweets, Facebook posts, Wikipedia entries, etc
- ❖ **Sesgo de retroalimentación:** esto ocurre cuando el modelo en sí mismo influye la generación del dato que lo va a entrenar.

# Tipo de sesgo en generación automática

- ❖ **Sesgo por omisión de información:** este tipo de sesgo ocurre cuando faltan variables relevantes para la caracterización del problema.
- ❖ **Sesgo de deriva de sistema:** la deriva ocurre cuando el sistema de generación de datos cambia con el tiempo.
- ❖ **Sesgo de contenido social:** ocurre cuando se incluye información con sesgos sociales, como estereotipos de género y raza.
- ❖ **Sesgo de respuesta o de opinión:** ocurre cuando el contenido es generado por personas, reviews on Amazon, Twitter tweets, Facebook posts, Wikipedia entries, etc
- ❖ **Sesgo de retroalimentación:** esto ocurre cuando el modelo en sí mismo influye la generación del dato que lo va a entrenar.



# Tipo de sesgo en generación automática

- ❖ **Sesgo por omisión de información:** este tipo de sesgo ocurre cuando faltan variables relevantes para la caracterización del problema.
- ❖ **Sesgo de deriva de sistema:** la deriva ocurre cuando el sistema de generación de datos cambia con el tiempo.
- ❖ **Sesgo de contenido social:** ocurre cuando se incluye información con sesgos sociales, como estereotipos de género y raza.
- ❖ **Sesgo de respuesta o de opinión:** ocurre cuando el contenido es generado por personas, reviews on Amazon, Twitter tweets, Facebook posts, Wikipedia entries, etc
- ❖ **Sesgo de retroalimentación:** esto ocurre cuando el modelo en sí mismo influye la generación del dato que lo va a entrenar.

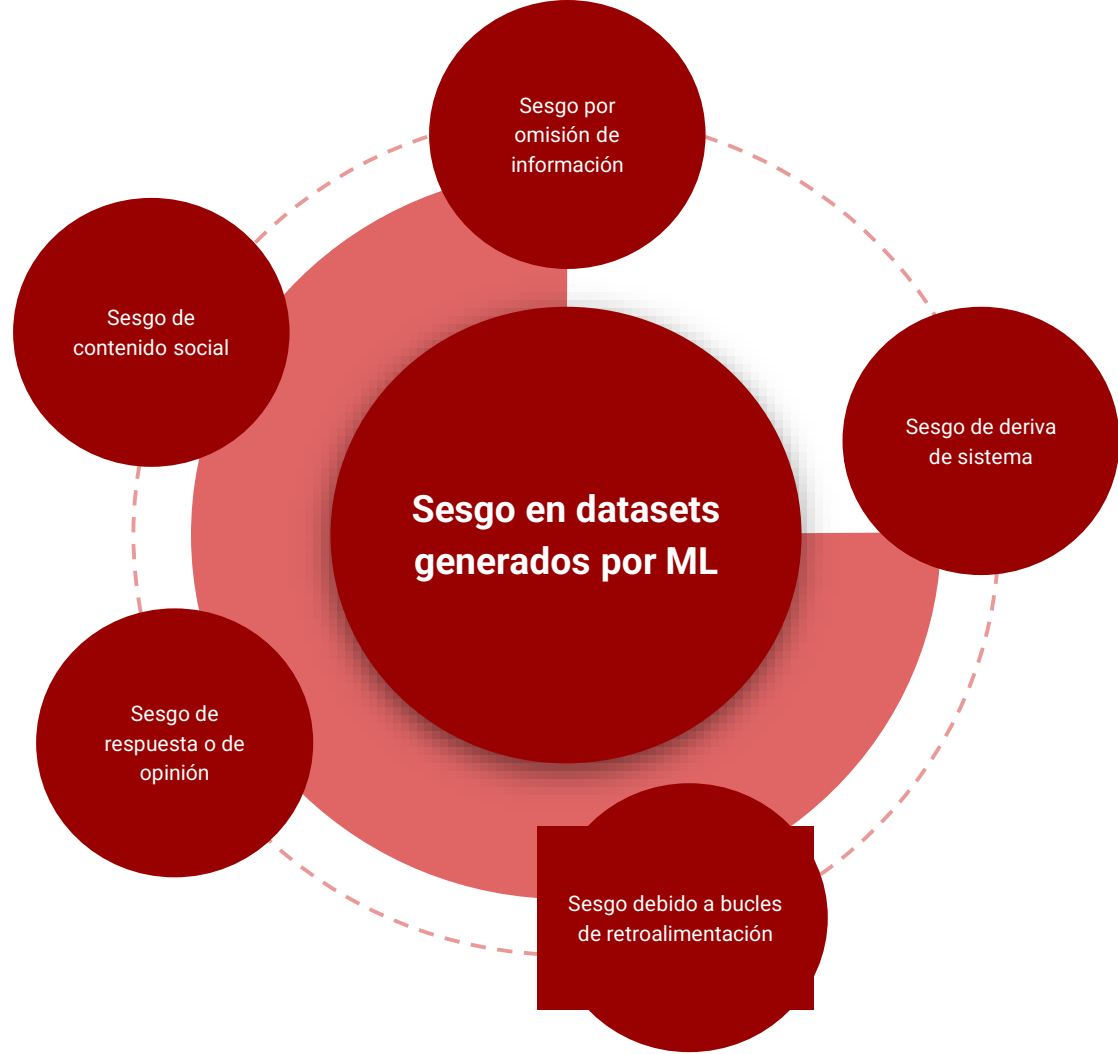
# Tipo de sesgo en generación automática

- ❖ **Sesgo por omisión de información:** este tipo de sesgo ocurre cuando faltan variables relevantes para la caracterización del problema.
- ❖ **Sesgo de deriva de sistema:** la deriva ocurre cuando el sistema de generación de datos cambia con el tiempo.
- ❖ **Sesgo de contenido social:** ocurre cuando se incluye información con sesgos sociales, como estereotipos de género y raza.
- ❖ **Sesgo de respuesta o de opinión:** ocurre cuando el contenido es generado por personas, reviews on Amazon, Twitter tweets, Facebook posts, Wikipedia entries, etc
- ❖ **Sesgo de retroalimentación:** esto ocurre cuando el modelo en sí mismo influye la generación del dato que lo va a entrenar.

# Tipo de sesgo en generación automática

- ❖ **Sesgo por omisión de información:** este tipo de sesgo ocurre cuando faltan variables relevantes para la caracterización del problema.
- ❖ **Sesgo de deriva de sistema:** la deriva ocurre cuando el sistema de generación de datos cambia con el tiempo.
- ❖ **Sesgo de contenido social:** ocurre cuando se incluye información con sesgos sociales, como estereotipos de género y raza.
- ❖ **Sesgo de respuesta o de opinión:** ocurre cuando el contenido es generado por personas, reviews on Amazon, Twitter tweets, Facebook posts, Wikipedia entries, etc
- ❖ **Sesgo de retroalimentación:** esto ocurre cuando el modelo en sí mismo influencia la generación del dato que lo vá a entrenar.

# Melbourne housing market



# Ejercicio: Melbourne housing market

- ❖ Sesgo por omisión de información:??
- ❖ Sesgo de deriva de sistema:??
- ❖ Sesgo de contenido social:??
- ❖ Sesgo de respuesta o de opinión:??
- ❖ Sesgo de retroalimentación:??

# Sesgo en muestras estadísticas



# Sesgo en muestras estadísticas



# Tipos de sesgo de muestreo

- ❖ **Autoselección:** La autoselección ocurre cuando los participantes del estudio ejercen control sobre la decisión de participar en el estudio hasta cierto punto.
- ❖ **Selección de un área específica:** Los participantes del estudio se seleccionan de ciertas áreas, mientras que otras áreas no están representadas en la muestra.
- ❖ **Exclusión:** Algunos grupos de la población están excluidos del estudio.



# Tipos de sesgo de muestreo

- ❖ **Autoselección:** La autoselección ocurre cuando los participantes del estudio ejercen control sobre la decisión de participar en el estudio hasta cierto punto.
- ❖ **Selección de un área específica:** Los participantes del estudio se seleccionan de ciertas áreas, mientras que otras áreas no están representadas en la muestra.
- ❖ **Exclusión:** Algunos grupos de la población están excluidos del estudio.

# Tipos de sesgo de muestreo

- ❖ **Autoselección:** La autoselección ocurre cuando los participantes del estudio ejercen control sobre la decisión de participar en el estudio hasta cierto punto.
- ❖ **Selección de un área específica:** Los participantes del estudio se seleccionan de ciertas áreas, mientras que otras áreas no están representadas en la muestra.
- ❖ **Exclusión:** Algunos grupos de la población están excluidos del estudio.

# Tipos de sesgo de muestreo

- ❖ **Sesgo de supervivencia:** El sesgo de supervivencia ocurre cuando una muestra se concentra en sujetos que pasaron el proceso de selección e ignora a los sujetos que no pasaron el proceso de selección.
- ❖ **Selección previa de los participantes:** Los participantes del estudio se reclutan solo de grupos particulares.

# Tipos de sesgo de muestreo

- ❖ **Sesgo de supervivencia:** El sesgo de supervivencia ocurre cuando una muestra se concentra en sujetos que pasaron el proceso de selección e ignora a los sujetos que no pasaron el proceso de selección.
- ❖ **Selección previa de los participantes:** Los participantes del estudio se reclutan solo de grupos particulares.

# Melbourne Housing Market Snapshot



# **Ejercicio: Melbourne Housing Market**

- ❖ **Autoselección: ??**
- ❖ **Selección de un área específica: ??**
- ❖ **Exclusión: ??**
- ❖ **Sesgo de supervivencia: ??**
- ❖ **Selección previa de los participantes: ??**

# Cómo identificar y corregir el sesgo

01

Planificación

- Utilización de protocolos rigurosos.
- Definición clara, precisa y concisa de objetivos.
- Empleo de información relacionada a la investigación obtenida a partir de clínicos, epidemiólogos, estadísticos.

02

Comienzo

- Determinación de sesgos de muestreo
- Previsión de abandonos y minimización de pérdidas de seguimiento
- Entrenamiento de investigadores
- Utilización de instrumentos de medición válidos y confiables

03

Desarrollo y finalización

- Detección de incoherencias en las mediciones
- Corrección estadística de sesgos
- Interpretación de los resultados en función de los sesgos cometidos

# Cómo identificar y corregir el sesgo

- ❖ **Estudiar las posibilidades de ingreso de sesgo en forma cuidadosa**
- ❖ Definir la población objetivo y el marco de muestreo (la lista de individuos de donde se realizará la muestra).
- ❖ Corregir el diseño de muestreo para compensar por desbalances.



# Cómo identificar y corregir el sesgo

- ❖ Estudiar las posibilidades de ingreso de sesgo en forma cuidadosa
- ❖ **Definir la población objetivo y el marco de muestreo (la lista de individuos de donde se realizará la muestra).**
- ❖ Corregir el diseño de muestreo para compensar por desbalances.

# Cómo identificar y corregir el sesgo

- ❖ Estudiar las posibilidades de ingreso de sesgo en forma cuidadosa
- ❖ Definir la población objetivo y el marco de muestreo (la lista de individuos de donde se realizará la muestra).
- ❖ **Corregir el diseño de muestreo para compensar por desbalances.**

# Cómo identificar y corregir el sesgo

- ❖ Ingresar pesos en el modelo para corregir desbalance en muestreo ya realizado.
- ❖ Evitar muestreo de conveniencia
- ❖ Realizar encuestas cortas y ágiles
- ❖ Seguir a los que no responden

# Cómo identificar y corregir el sesgo

- ❖ Ingresar pesos en el modelo para corregir desbalance en muestreo ya realizado.
- ❖ **Evitar muestreo de conveniencia**
- ❖ Realizar encuestas cortas y ágiles
- ❖ Seguir a los que no responden

# Cómo identificar y corregir el sesgo

- ❖ Ingresar pesos en el modelo para corregir desbalance en muestreo ya realizado.
- ❖ Evitar muestreo de conveniencia
- ❖ **Realizar encuestas cortas y ágiles**
- ❖ Seguir a los que no responden

# Cómo identificar y corregir el sesgo

- ❖ Ingresar pesos en el modelo para corregir desbalance en muestreo ya realizado.
- ❖ Evitar muestreo de conveniencia
- ❖ Realizar encuestas cortas y ágiles
- ❖ **Seguir a los que no responden**

# Sesgo de procesamiento

- ❖ Tratamiento de datos faltantes
- ❖ Unión de distintas cohortes de datos
- ❖ Escalar y normalizar
- ❖ Cherry picking de todos los colores y formas



# Bibliografía

- ❖ [Los Sesgos en Investigación Clínica. Carlos Manterola, Tamara Otzen. Int. J. Morphol., 33\(3\):1156-1164, 2015](#)
- ❖ Särndal, C. E. (2007), “The calibration approach in survey theory and practice”, Survey Methodology, vol. 33, N°
- ❖ Rosenbaum, P. R. y D. B. Rubin (1983), “The central role of the propensity score in observational studies for causal effects”, Biometrika, vol. 70, N° 1.
- ❖ John Tukey, Exploratory Data Analysis, Pearson Modern Classics
- ❖ [Recomendaciones para eliminar el sesgo de selección en las encuestas de hogares en la coyuntura de la enfermedad por coronavirus \(COVID-19\)](#)
- ❖ [A. Torralba, A. Efros. Unbiased Look at Dataset Bias. IEEE Conference on Computer Vision and Pattern Recognition \(CVPR\), 2011](#)
- ❖ [Tolga Bolukbasi, Kai-Wei Chang, James Zou, Venkatesh Saligrama, Adam Kalai \(2016\) Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings](#)
- ❖ [FIVE TYPES OF STATISTICAL BIAS TO AVOID IN YOUR ANALYSES Jenny Gutbezahl](#) Harvard Business school online.
- ❖ [Julia Angwin, Jeff Larson, Surya Mattu, and Lauren Kirchner. “Machine bias: There’s software used across the country to predict future criminals, and it’s biased against blacks”. ProPublica \(May 23, 2016\).](#)
- ❖ Understanding bias. Prabhakar Krishnamurthy. <https://towardsdatascience.com/survey-d4f168791e57>